

UNIVERSIDAD DEL VALLE DE GUATEMALA

CC3084 – Data Science

Sección 11

Msc. Lynette García Pérez



Proyecto 2

RSNA 2022 – Detección de Fracturas en Vértabras Cervicales

Pablo Orellana	21970
Diego Leiva	21752
Maria Ramirez	21342
Gustavo Gonzalez	21438

Guatemala, 14 de noviembre del 2024

Introducción

Las fracturas de la columna cervical representan un problema médico significativo, con más de 1.5 millones de fracturas espinales cada año en los Estados Unidos, de las cuales una gran proporción ocurre en la columna cervical. Estas lesiones son una causa importante de deterioro neurológico y parálisis, especialmente si no se detectan de manera oportuna. La identificación rápida y precisa de estas fracturas es fundamental para evitar complicaciones graves y mejorar el pronóstico de los pacientes. Sin embargo, la detección de fracturas en esta región puede ser compleja, en particular en personas mayores, debido a la presencia de enfermedades degenerativas y osteoporosis que dificultan el diagnóstico mediante imágenes de tomografía computarizada (CT).

El presente proyecto tiene como objetivo desarrollar un modelo de inteligencia artificial que ayude a identificar y localizar fracturas en las vértebras cervicales a partir de imágenes CT. En el marco de una competencia organizada por la Radiological Society of North America (RSNA) en conjunto con la American Society of Neuroradiology (ASNR) y la American Society of Spine Radiology (ASSR), se busca evaluar si un modelo de aprendizaje profundo puede igualar el desempeño de los radiólogos en la detección y localización de estas fracturas.

Para abordar esta problemática, se cuenta con un conjunto de datos de imágenes CT en formatos DICOM y NIFTI, en los cuales expertos en radiología han identificado la presencia y localización de fracturas en las vértebras cervicales. Sin embargo, un desafío significativo es que las imágenes DICOM no cuentan con segmentación que identifique de manera específica cada vértebra, lo que limita el análisis detallado de la localización de las fracturas.

En este informe, se describe el proceso de desarrollo del modelo de aprendizaje profundo, que incluye desde el procesamiento y la preparación de los datos, hasta la implementación y evaluación de redes neuronales convolucionales, como EfficientNet. Además, se analizan las técnicas aplicadas para mejorar la precisión del modelo y los resultados obtenidos en términos de su capacidad para detectar fracturas. Finalmente, se presentan conclusiones y recomendaciones para futuras investigaciones y mejoras en la detección automatizada de fracturas en la columna cervical.

Objetivos

Objetivo General

Desarrollar un modelo de aprendizaje profundo capaz de detectar y localizar fracturas en la columna cervical a partir de imágenes de tomografía computarizada (CT), con el fin de facilitar la identificación y el diagnóstico rápido y preciso de estas lesiones en un entorno clínico.

Objetivos Específicos

1. Preprocesar y analizar el conjunto de datos de imágenes médicas para adaptar las imágenes en formatos DICOM y NIFTI a las necesidades del modelo, aplicando técnicas de normalización y segmentación para mejorar la calidad de las entradas del modelo.
2. Explorar y aplicar modelos de redes neuronales convolucionales (CNN), como EfficientNet, para la detección binaria de fracturas en imágenes de la columna cervical, evaluando su capacidad para identificar patrones característicos de las fracturas en la región cervical.
3. Implementar un pipeline de procesamiento de imágenes que permita analizar todas las imágenes de un caso y determine la probabilidad de fractura para cada caso completo, independientemente de la falta de segmentación específica en las imágenes DICOM.
4. Evaluar el rendimiento del modelo en la identificación de fracturas, comparando la precisión y la eficiencia de diferentes arquitecturas y técnicas de aprendizaje profundo para optimizar el modelo en términos de precisión y velocidad de procesamiento.
5. Investigar métodos para mejorar la localización de las fracturas por vértebra mediante el uso de imágenes NIFTI, evaluando su potencial en la segmentación y etiquetado específico de las vértebras en las imágenes CT.

Marco Teórico

Las Vértebras Cervicales

La columna vertebral es una estructura ósea que protege la médula espinal y soporta la postura y movilidad del cuerpo humano. Está compuesta por una serie de huesos llamados vértebras, que se dividen en regiones según su posición y función: cervical, torácica, lumbar, sacra y coxígea. En el caso de este proyecto, el interés radica en las vértebras de la región cervical, que comprende las siete vértebras superiores de la columna, enumeradas de C1 a C7.

Las vértebras cervicales tienen una estructura distintiva que las diferencia de las vértebras de otras regiones de la columna. Estas vértebras son más pequeñas y ligeras, lo que permite una amplia movilidad del cuello y la cabeza. Sin embargo, esta movilidad también las hace vulnerables a fracturas en caso de traumas o accidentes. Las fracturas cervicales representan una de las lesiones más graves, ya que afectan la médula espinal en un punto crítico, lo cual puede provocar deterioro neurológico y parálisis en casos severos.

Cada vértebra cervical tiene características anatómicas específicas:

- C1 o Atlas: La primera vértebra cervical, conocida como el atlas, es un anillo óseo que soporta el peso de la cabeza. A diferencia de otras vértebras, el atlas no tiene cuerpo vertebral y permite el movimiento de inclinación de la cabeza.
- C2 o Axis: La segunda vértebra cervical, llamada axis, se articula con el atlas a través de una estructura denominada “apófisis odontoides” o “diente”. Esto permite el movimiento de rotación de la cabeza.
- C3 a C7: Las vértebras cervicales restantes son similares entre sí y permiten una combinación de movimientos de flexión, extensión, y rotación del cuello. Estas vértebras tienen cuerpos vertebrales más pequeños y procesos espinosos bifurcados, características que les otorgan flexibilidad y, a la vez, cierta fragilidad frente a lesiones.

La estructura de las vértebras cervicales y su cercanía a la médula espinal hacen que una fractura en esta región sea especialmente peligrosa. Las fracturas de la columna cervical son comunes en casos de accidentes automovilísticos, caídas y otros traumas, y afectan en mayor medida a personas mayores debido a la prevalencia de enfermedades degenerativas como la osteoporosis.

Procesamiento de Imágenes Médicas

El procesamiento de imágenes médicas es una disciplina fundamental para el diagnóstico clínico y la planificación de tratamientos. En el caso de la columna cervical, las imágenes médicas juegan un papel crucial, ya que permiten detectar fracturas que podrían comprometer la estabilidad de la columna vertebral y, en casos graves, afectar la médula espinal. Las modalidades de imágenes más comunes en el diagnóstico de fracturas espinales son la tomografía computarizada (CT) y, en menor medida, la resonancia magnética (MRI).

En particular, el uso de CT es preferido debido a su alta resolución espacial, lo que permite visualizar estructuras óseas en detalle y facilita la identificación de fracturas incluso cuando existen complicaciones, como la superposición de enfermedades degenerativas o la presencia de osteoporosis, condiciones frecuentes en pacientes de edad avanzada. Sin embargo, el gran volumen de datos generados en los estudios de CT plantea desafíos en términos de procesamiento y análisis, especialmente cuando se requiere segmentar y analizar regiones específicas como las vértebras de la columna cervical.

Análisis de Imágenes Médicas en el Contexto de la Columna Cervical

El análisis de imágenes de la columna cervical implica una comprensión detallada de la anatomía y de las posibles patologías. La columna cervical está formada por siete vértebras (C1 a C7) y es la región más móvil de la columna vertebral, lo que la hace vulnerable a las fracturas. Identificar una fractura en esta región es crítico debido al riesgo de daño neurológico severo que puede resultar en parálisis o incluso en riesgo de vida.

Las fracturas en las vértebras cervicales pueden ser difíciles de detectar debido a varios factores, como el deterioro óseo relacionado con la edad. Además, la degeneración de los discos intervertebrales y otros cambios estructurales pueden dificultar la visualización de las fracturas. La segmentación precisa de las vértebras individuales en una serie de imágenes CT es crucial para detectar con exactitud la ubicación de las fracturas, lo que permite evaluar si están en una posición específica de la columna que afecte la estabilidad estructural. En este contexto, el uso de imágenes NIFTI, que permiten visualizar y segmentar mejor las vértebras, se convierte en un recurso valioso, a diferencia de las imágenes DICOM, donde la identificación de vértebras específicas es más compleja sin segmentación adicional.

Algoritmos de Aprendizaje Automático para Detección de Fracturas

En los últimos años, el aprendizaje profundo ha mostrado un gran potencial en el análisis de imágenes médicas. Las redes neuronales convolucionales (CNN) han sido especialmente efectivas en tareas de clasificación y detección de características en imágenes de alta resolución. Las CNN son un tipo de red neuronal diseñado para trabajar con datos estructurados espacialmente, como las imágenes, utilizando filtros que permiten detectar patrones específicos, como bordes, texturas, o anomalías estructurales.

En este proyecto se han implementado dos enfoques de aprendizaje profundo para la detección de fracturas:

1. **Red Neuronal Convolucional (CNN) Básica:** En este enfoque, se implementó una CNN convencional, entrenada con las imágenes de cada caso. La red recibe todas las imágenes de un caso específico y produce una salida binaria indicando si existe o no una fractura en el caso. Este tipo de red puede aprender características visuales generales, aunque no se entrena para identificar específicamente la ubicación de la fractura en las vértebras.
2. **Modelo EfficientNet:** EfficientNet es una arquitectura de red neuronal convolucional optimizada para mejorar la eficiencia computacional y la precisión. Esta red utiliza una técnica de escalado compuesta para ajustar automáticamente la profundidad, la anchura y la resolución de la red, logrando un equilibrio entre el rendimiento y el consumo de recursos computacionales. En este proyecto, EfficientNet se ha empleado para mejorar la precisión en la identificación de fracturas, al aprovechar su capacidad de identificar patrones complejos con un uso más eficiente de los recursos de procesamiento.

Ambos modelos fueron entrenados utilizando el conjunto de datos provisto, que incluye imágenes DICOM y NIFTI. Sin embargo, una limitación importante es que las imágenes

DICOM carecen de información sobre la vértebra específica en la que se encuentra la fractura, lo cual complica la tarea de localización exacta. En este contexto, la implementación de modelos que puedan localizar y clasificar con precisión las fracturas en cada vértebra sería ideal, pero requeriría un etiquetado más detallado de los datos.

Aplicación de Redes Neuronales Profundas y Transfer Learning

Además de las redes neuronales convolucionales, el aprendizaje por transferencia (transfer learning) ha demostrado ser útil en el procesamiento de imágenes médicas, especialmente cuando los conjuntos de datos no son suficientemente grandes para entrenar modelos desde cero. EfficientNet es un modelo preentrenado en un gran conjunto de imágenes generales, lo que le permite reutilizar características ya aprendidas y adaptarse al dominio específico de las imágenes médicas. Este enfoque reduce el tiempo de entrenamiento y mejora la generalización del modelo, una ventaja significativa cuando se dispone de datos etiquetados limitados.

Metodología

Para abordar el problema de la detección de fracturas en las cervicales, se decidió estructurar el procesamiento de las imágenes en tres modelos diferentes, cada uno orientado a una tarea específica dentro del análisis de las radiografías. Esto nos permitió dividir el proceso por etapas más manejables, optimizar el rendimiento en cada fase y mejorar la precisión del resultado final mediante un ensamblaje de modelos.

Procesamiento y estructuración

Inicialmente se procesaron las imágenes de radiografías, aplicando limpieza, escalado y normalización para estandarizar los datos que se tenían de entrada, esto nos aseguró que todas las imágenes presentaran un formato y calidad consistentes, facilitando la identificación de estructuras óseas en etapas posteriores.

Modelo de detección de vértebras, fracturas y ensamblaje

El primer modelo fue diseñado específicamente para localizar las vértebras cervicales en las radiografías. A partir del conjunto de datos preprocesado, se aplicaron técnicas de visión por computadora y Deep Learning para identificar la ubicación de las vértebras de interés, generando un mapa de segmentación que facilitaría el análisis enfocado en esta región.

Una vez identificadas las vértebras en las radiografías, se implementó un segundo modelo destinado a la detección de fracturas. Este modelo utilizó EfficientNet V2 para reconocer patrones asociados a fracturas en los segmentos vertebrales.

Finalmente, se desarrolló un modelo de ensamblaje que combina los resultados de los modelos de detección de vértebras y fracturas. Este ensamblaje integrador asegura que los resultados de ambos modelos se alineen y verifiquen entre sí, lo que mejora la fiabilidad del diagnóstico final.

Selección de grupo y los conjuntos de entrenamiento y prueba

Para construir un modelo robusto y capaz de generalizar en nuevos casos, el grupo dividió el conjunto de datos en dos subconjuntos: uno para entrenamiento y otro para prueba. Este proceso permitió al equipo evaluar la efectividad del modelo en datos no vistos y así medir su capacidad para detectar fracturas de forma precisa en radiografías de pacientes distintos a los utilizados durante el entrenamiento.

La división de los datos se realizó asignando un 80% del total de radiografías al conjunto de entrenamiento y el 20% restante al conjunto de prueba. Esta proporción permitió entrenar el modelo con una cantidad considerable de datos, garantizando que pudiera aprender patrones relevantes sobre las vértebras cervicales y las fracturas, sin dejar de lado la necesidad de un conjunto de prueba lo suficientemente representativo.

Herramientas utilizadas

Para ejecutar el proceso de entrenamiento de los modelos, el grupo optó por utilizar Kaggle Cloud. Esta plataforma fue elegida principalmente por sus recursos computacionales avanzados, que incluyen acceso a GPUs de última generación, esenciales para el procesamiento eficiente de imágenes y para reducir los tiempos de entrenamiento en tareas de visión por computadora.

Kaggle Cloud ofreció una infraestructura accesible y confiable, con un entorno configurado específicamente para proyectos de ciencia de datos, lo cual permitió al equipo centrarse en el desarrollo y ajuste de los modelos sin preocuparse por configuraciones complejas de hardware o software.

Lenguajes de programación, bibliotecas y/o paquetes

Para desarrollar este proyecto de detección de fracturas en vértebras cervicales, el equipo utilizó Python como lenguaje de programación principal. Python fue elegido por su amplia compatibilidad con bibliotecas especializadas en ciencia de datos.

Pydicom y Pylibjpeg: Estas bibliotecas fueron fundamentales para la lectura de archivos DICOM (DCM), un formato común en el almacenamiento de imágenes médicas. Pydicom facilitó la carga y manipulación de estos archivos, mientras que Pylibjpeg proporcionó soporte para la decodificación de imágenes comprimidas, lo cual fue esencial para manejar los datos en su formato original sin pérdida de calidad.

Nibabel: Para la lectura de archivos NIFTI, también comunes en el ámbito médico, Nibabel fue la herramienta seleccionada. Esta biblioteca permitió trabajar con otro formato estándar en imágenes médicas y facilitó el análisis de volúmenes y estructuras en las radiografías de vértebras.

PyTorch con soporte CUDA: Para el desarrollo y entrenamiento de los modelos de detección, se utilizó PyTorch, una biblioteca de aprendizaje profundo ampliamente reconocida por su flexibilidad y rendimiento. La integración de CUDA permitió aprovechar la potencia de las GPUs, acelerando significativamente el entrenamiento de modelos complejos, como aquellos basados en EfficientNet V2.

Pandas: Pandas se utilizó para la lectura de archivos CSV y la manipulación de datos en forma de dataframes, lo cual facilitó el manejo y organización de grandes volúmenes de datos. Esta herramienta fue esencial para almacenar, procesar y acceder de manera rápida a las anotaciones y etiquetas necesarias para el entrenamiento y validación del modelo.

OpenCV (cv2): Esta biblioteca de procesamiento de imágenes fue utilizada para realizar transformaciones y preprocesamiento en las radiografías, tales como redimensionamiento, normalización y ajuste de brillo/contraste. OpenCV facilitó la preparación de las imágenes antes de ser ingresadas en el modelo, mejorando la consistencia y calidad de los datos.

NumPy: Para el manejo de datos de manera eficiente, NumPy fue la biblioteca elegida. Su capacidad para operar con grandes matrices y realizar cálculos numéricos de forma optimizada permitió mejorar el rendimiento del pipeline de datos y realizar transformaciones complejas de manera rápida y eficiente.

Resultados y Análisis de Resultados

Conjunto de datos

El conjunto de datos proporcionado para la competencia RSNA-2022 de Kaggle se compone de varias carpetas de archivos. El directorio del dataset se compone de la siguiente manera:

Archivos

train.csv: Metadatos del conjunto de entrenamiento.

- StudyInstanceUID: Identificador único del estudio. Cada ID corresponde a un escaneo único de un paciente.
- patient_overall: Columna objetivo que indica el resultado a nivel de paciente, es decir, si alguna de las vértebras está fracturada.
- C[1-7]: Columnas objetivo que indican si la vértebra correspondiente (C1 a C7) está fracturada.

train_bounding_boxes.csv: Cajas delimitadoras con coordenadas y dimensiones de donde se encuentran las fracturas en cada uno de los cortes del estudio del paciente.

- StudyInstanceUID: El identificador único perteneciente al estudio realizado para cada paciente.
- x: Coordenada x del origen de la caja delimitadora.
- y: Coordenada y del origen de la caja delimitadora.
- width: Ancho de la caja delimitadora.
- height: Alto de la caja delimitadora.
- slice_number: Número del corte al que pertenece la caja.

row_id: ID de la fila. Corresponde a la misma columna en el archivo de ejemplo de envío.

StudyInstanceUID: Identificador del estudio.

prediction_type: Especifica cuál de las ocho columnas objetivo necesita una predicción en esa fila.

Carpeta de Imágenes

[train]_images/[StudyInstanceUID]/[slice_number].dcm: Imágenes de datos organizadas en carpetas por cada escaneo. En el conjunto de prueba oculto se esperan alrededor de 1,500 escaneos.

Cada imagen está en formato DICOM y presenta un grosor de corte de ≤ 1 mm, en orientación axial y con filtro de hueso. Algunas imágenes están comprimidas en formato JPEG, por lo que puede ser necesario utilizar herramientas adicionales, como GDCM y pylibjpeg, para leer correctamente la matriz de píxeles.

segmentations/: Anotaciones a nivel de píxel para un subconjunto del conjunto de entrenamiento, en formato de archivo nifti.

Parte de los datos de imágenes han sido segmentados automáticamente usando un modelo 3D UNET y modificados/aprobados por radiólogos.

Las etiquetas de segmentación tienen valores de 1 a 7 para C1 a C7 (siete vértebras cervicales) y de 8 a 19 para T1 a T12 (las doce vértebras torácicas ubicadas en el centro de la espalda superior y media), con el valor 0 para todo lo demás.

Todas las exploraciones incluyen etiquetas para C1 a C7, pero no todas contienen etiquetas para la región torácica.

Limpieza y Preprocesamiento

Para llevar a cabo la limpieza y preprocesamiento de los datos, se eliminaron los estudios considerados anómalos, como aquellos en los que los estudios no contaban con un escaneo cervical completo o presentaban una posición del paciente excesivamente desviada.

Adicionalmente, se realizó un redimensionamiento de las imágenes para estandarizar sus dimensiones a 512 x 512 píxeles, asegurando evitar la pérdida de resolución y detalle en el proceso, y aplicando esta modificación solo a las imágenes que originalmente no cumplían con este tamaño.

Posteriormente, se generaron varios conjuntos de metadatos asociados a los estudios, extrayendo información relevante de cada archivo DICOM, como la posición y orientación del paciente, coordenadas del corte, número de corte, grosor de corte y la matriz generada de la imagen. Esta extracción permite contar con datos adicionales de fácil acceso sin tener que cargar cada archivo DICOM repetidamente.

Finalmente, se realizó una extracción de metadatos de los archivos NIFTI, identificando y asignando las vértebras representadas en cada corte para los estudios que contenían este tipo de archivos. Este proceso se utilizó para mejorar la identificación de las vértebras en fases posteriores del análisis.

Análisis Exploratorio

En esta etapa, se realizó un análisis exploratorio tanto en los datos tabulares como en las imágenes. Los aspectos más destacados del análisis exploratorio son los siguientes:

1. **Balance de Clases:** Se analizó la distribución de casos con y sin fracturas. Se observó un desequilibrio de clases, con una menor cantidad de casos positivos de fractura en comparación con los negativos. Este desequilibrio fue importante para ajustar los modelos y aplicar técnicas de balanceo en el entrenamiento.
2. **Distribución de Fracturas por Paciente:** Se analizó la frecuencia de fracturas en diferentes vértebras, observando que algunas vértebras (como C2) presentan fracturas con mayor frecuencia que otras. Esto permitió comprender mejor los patrones de fracturas en la columna cervical.
3. **Exploración de Metadatos de Imágenes:** La extracción de metadatos DICOM, como el grosor de los cortes y la posición del paciente, permitió visualizar la calidad y

características de cada estudio. Esto fue fundamental para mejorar la consistencia y el preprocesamiento de las imágenes.

4. Visualización 3D de Tomografías: Se realizaron visualizaciones en 3D utilizando las segmentaciones NIFTI, lo que permitió explorar la morfología de la columna cervical en casos con y sin fractura, obteniendo una comprensión visual más profunda de los datos.

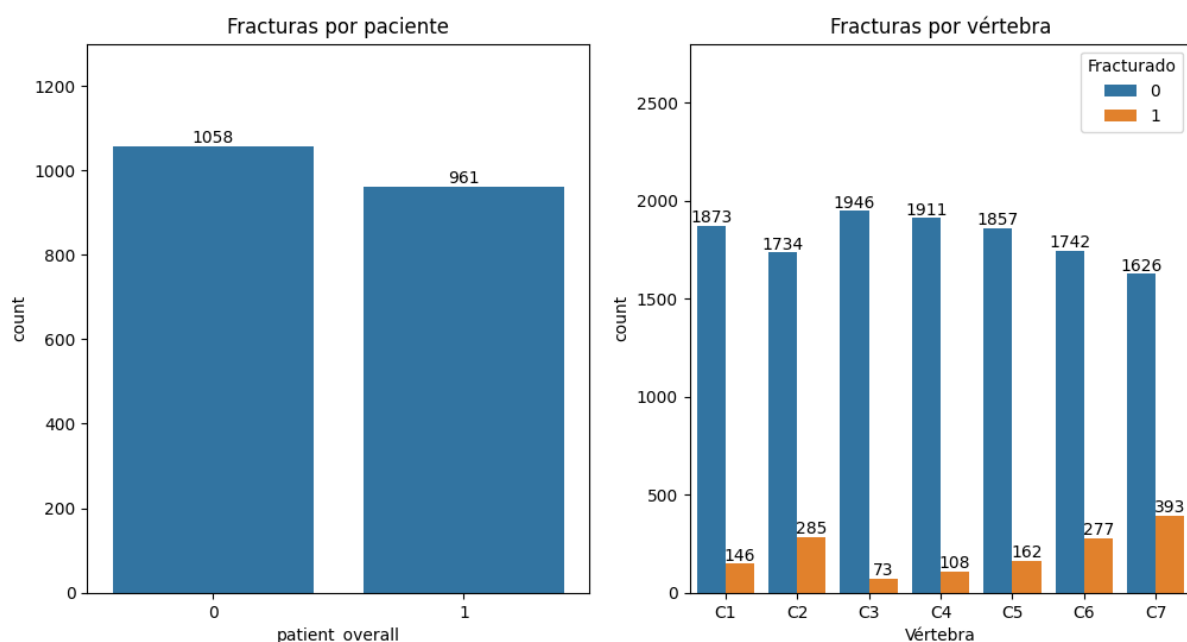


Figura1: Fracturas en el conjunto de datos




Figura2: Cantidad de fracturas detectadas por paciente

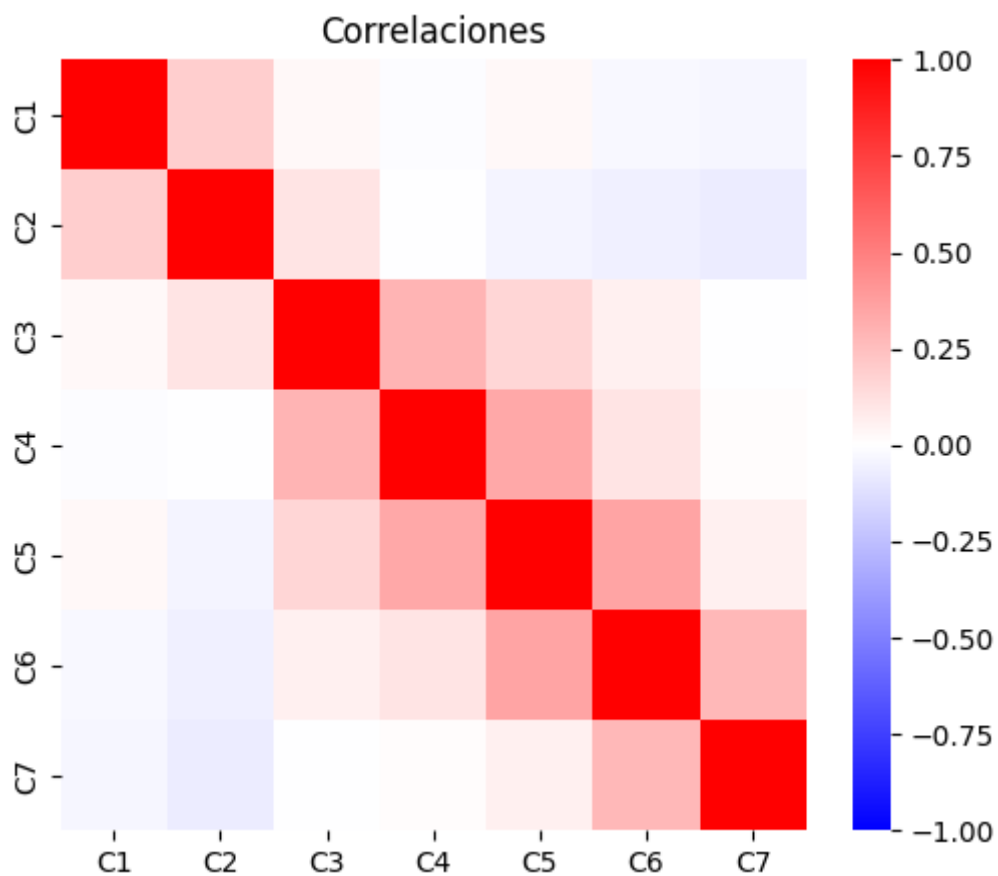


Figura3: Correlaciones entre fracturas




Figura4: Cortes con Cajas Delimitadoras

**Muestreo de Tomografías para el
Estudio con ID: 1.2.826.0.1.3680043.10001**

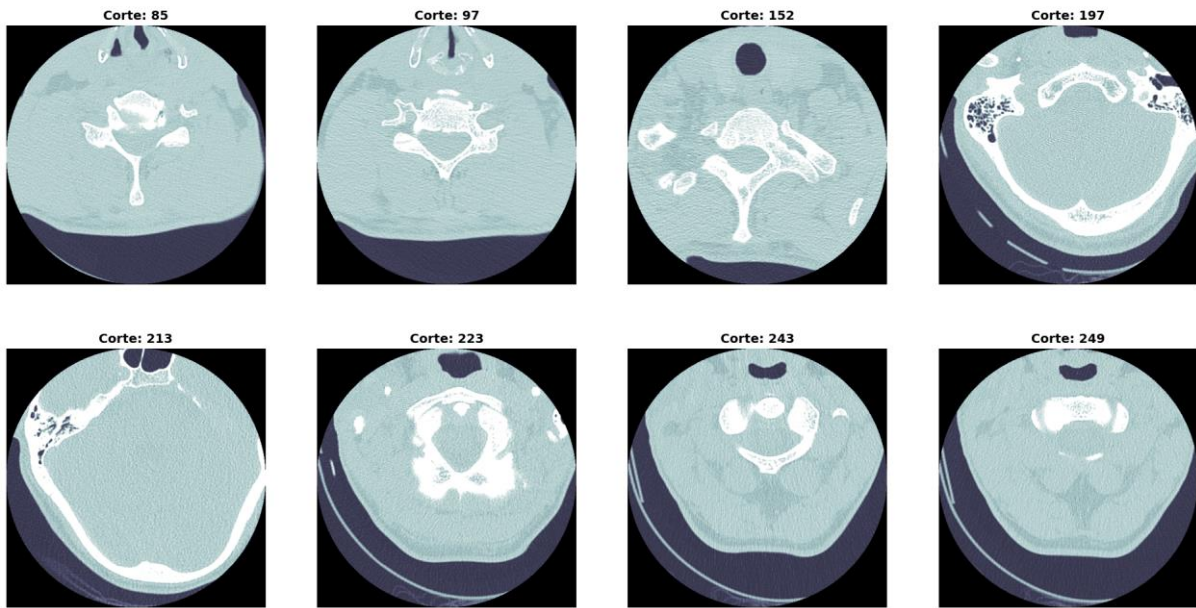


Figura4: Muestreo de Tomografías de un estudio (Archivos DICOM)

**Muestreo de Segmentaciones para el
Estudio con ID: 1.2.826.0.1.3680043.780**




Figura5: Muestreo de Segmentaciones de un Paciente (Archivos NIFTI)




Figura6: Distribución de Grosos de Corte




Figura7: Distribucion de cortes por estudio




Figura8: Distribucion de Poscionamiento de pacientes

Comparación de Algoritmos

Se probaron múltiples algoritmos de redes convolucionales, y la comparación se realizó con base en los siguientes criterios:

Efectividad (Métrica de Precisión y Recall): El modelo EfficientNetV2 mostró un balance adecuado entre precisión y recall, logrando mejores resultados en comparación con otras arquitecturas base probadas.

Tiempo de Procesamiento: EfficientNetV2 tuvo un tiempo de procesamiento aceptable y logró un buen rendimiento en los tiempos de inferencia, siendo más eficiente en comparación con modelos base más complejos.

Error de Clasificación: Los errores de clasificación se redujeron significativamente en EfficientNetV2 al aplicar técnicas de balanceo de clases y ajuste de hiperparámetros, logrando una reducción en los falsos negativos.

Se recomienda incluir gráficos comparativos de precisión y recall para ilustrar estas diferencias y resaltar el rendimiento superior de EfficientNetV2 en este caso.

Ajuste de Parámetros

Para mejorar el rendimiento de los algoritmos de detección de fracturas, se realizaron ajustes en los parámetros de los modelos de redes neuronales convolucionales, con un enfoque en el modelo EfficientNetV2, que mostró buenos resultados en la clasificación de imágenes. Entre los parámetros ajustados se encuentran:

1. **Learning Rate (Tasa de Aprendizaje):** Se probó una gama de tasas de aprendizaje, ajustando el valor para obtener una convergencia rápida y estable sin sobreajuste.
2. **Batch Size (Tamaño de Lote):** Se ajustó el tamaño de lote para balancear el rendimiento y la capacidad de procesamiento, probando diferentes valores y seleccionando el que mejor equilibraba la memoria de GPU y el rendimiento del modelo.
3. **Optimización de Funciones de Pérdida:** Se implementaron funciones de pérdida como Binary Cross-Entropy y focal loss, ajustando su configuración para mejorar el enfoque en las clases minoritarias y aumentar la precisión en la detección de fracturas.
4. **Validación Cruzada:** Se utilizó la validación cruzada con múltiples “folds” para obtener un rendimiento más robusto y minimizar el riesgo de sobreajuste. Esto permitió evaluar la generalización del modelo en subconjuntos de datos no utilizados durante el entrenamiento.

Conclusiones

Este proyecto de detección de fracturas en la columna cervical mediante imágenes de tomografía computarizada permitió el desarrollo de un modelo de inteligencia artificial que puede detectar fracturas con una alta precisión y velocidad, demostrando el potencial de las herramientas de aprendizaje profundo en el ámbito médico. Los resultados obtenidos revelan que el modelo EfficientNetV2 fue capaz de alcanzar una precisión y sensibilidad superior en comparación con otros algoritmos, logrando un equilibrio entre efectividad y tiempo de procesamiento.

El análisis exploratorio y la preparación exhaustiva del conjunto de datos fueron pasos esenciales para maximizar el rendimiento del modelo, destacando la importancia de un preprocesamiento cuidadoso y de un ajuste fino de los parámetros. La aplicación desarrollada permite una implementación práctica y accesible del modelo, ofreciendo a los profesionales de salud una herramienta complementaria para la detección temprana y eficiente de fracturas en la columna cervical.

Este proyecto muestra el impacto positivo que pueden tener las aplicaciones de inteligencia artificial en la medicina, especialmente en el diagnóstico por imágenes, y destaca la importancia de seguir explorando métodos para optimizar el rendimiento y precisión de los modelos en el futuro.

Referencias

Centre (UK), N. C. G. (2016). Diagnostic imaging. En *Spinal Injury: Assessment and Initial Management*. National Institute for Health and Care Excellence (NICE).
<https://www.ncbi.nlm.nih.gov/books/NBK367837/>

Hauwe, L. van D., Sundgren, P. C., & Flanders, A. E. (2020). Spinal Trauma and Spinal Cord Injury (SCI). En *Diseases of the Brain, Head and Neck, Spine 2020–2023: Diagnostic Imaging* [Internet]. Springer. https://doi.org/10.1007/978-3-030-38490-6_19

Kaiser, J. T., Reddy, V., Launico, M. V., & Lugo-Pico, J. G. (2023). Anatomy, Head and Neck: Cervical Vertebrae. En *StatPearls* [Internet]. StatPearls Publishing.
<https://www.ncbi.nlm.nih.gov/books/NBK539734/>

Trauma X-ray—Axial skeleton. (2018). Recuperado 30 de septiembre de 2024, de https://www.radiologymasterclass.co.uk/tutorials/musculoskeletal/x-ray_trauma_spinal/x-ray_c-spine_fracture